La Distance de Fermat en Apprentissage Automatique : Fondements Théoriques, Estimateurs et Cas d'Utilisation

Introduction aux Métriques Sensibles à la Densité

Dans le paysage contemporain de l'apprentissage automatique (machine learning) et des statistiques en grande dimension, la quantification précise de la similarité ou de la dissimilarité entre les points de données constitue le socle fondamental sur lequel reposent les algorithmes en aval. Traditionnellement, la distance euclidienne ou les métriques de Minkowski ont servi de choix par défaut pour le calcul de ces relations. Cependant, dans les espaces à haute dimension, ces métriques classiques subissent une dégradation sévère en raison du « fléau de la dimension », un phénomène géométrique où les distances entre deux points quelconques dans un grand ensemble de données tendent à converger vers une valeur similaire, rendant la discrimination spatiale inefficace.[1]

En outre, les données réelles n'occupent que très rarement l'intégralité de leur espace ambiant à haute dimension. Au lieu de cela, elles adhèrent typiquement à l'hypothèse de la variété (manifold assumption), reposant sur ou près d'une variété riemannienne de dimension inférieure plongée dans l'espace de dimension supérieure.[1] Dans de tels scénarios, la distance euclidienne entre deux points peut déformer de manière drastique leur véritable relation structurelle, en coupant à travers l'espace ambiant vide plutôt qu'en traversant la géométrie intrinsèque des données. Bien que les distances géodésiques intrinsèques répondent en partie à l'hypothèse de la variété, elles introduisent un second point aveugle : elles sont totalement agnostiques vis-à-vis de la distribution statistique sous-jacente des données. Elles ne parviennent pas à prendre en compte l'hypothèse des grappes (cluster assumption), qui postule que les points de données résidant dans des régions à haute densité sont intrinsèquement plus liés (ou partagent la même étiquette de classification) que ceux séparés par des vallées à faible densité ou des lacunes structurelles.[2]

Pour résoudre le double défi de la navigation sur la variété intrinsèque tout en respectant la densité de probabilité sous-jacente, la recherche mathématique a formalisé une classe de métriques axées sur la densité. Parmi celles-ci, la **distance de Fermat** occupe une place prépondérante. Selon les travaux fondamentaux et la littérature spécialisée, cette métrique est également connue sous diverses appellations équivalentes, telles que la « d-distance » ou la « métrique du chemin le plus court pondéré par une puissance » (power-weighted shortest path metric, ou p-wspm).[3] Inspirée par le principe de Fermat en optique géométrique (le principe du temps de trajet minimum), où la lumière traverse un milieu en minimisant le temps de transit par rapport à un indice de réfraction variable, la distance de Fermat trace des chemins à travers les données en minimisant une fonctionnelle de coût qui pénalise lourdement la traversée de régions clairsemées et à faible densité.[1]

L'intégration de la distance de Fermat dans les pipelines d'apprentissage automatique fournit une transformation conforme de la métrique euclidienne. Elle comprime les distances au sein des grappes à haute densité tout en élargissant exponentiellement les distances à travers les frontières à faible densité.[2] Ce rapport détaille de manière exhaustive les fondements mathématiques de la distance de Fermat telle qu'elle est strictement définie dans la littérature de référence, l'évolution de ses estimateurs (notamment la distance de Fermat à la mesure, ou FDTM, et les formulations adaptées à la dimension), ses implémentations algorithmiques, ainsi que ses applications avancées dans divers domaines de l'apprentissage automatique, allant de la classification semi-supervisée au clustering spectral, en passant par l'analyse topologique des données et l'apprentissage de représentations profondes.

Fondements Mathématiques et Consistance Asymptotique

La formalisation de la distance de Fermat jette un pont entre les estimations discrètes basées sur des échantillons et les limites macroscopiques continues. Les preuves théoriques validant son utilité en apprentissage automatique reposent fortement sur la percolation de premier passage euclidienne et le comportement des processus ponctuels de Poisson non homogènes.[1]

Le Cadre Microscopique : Distance de Fermat Discrète (ou d-distance)

Étant donné un ensemble de données fini $Q_n = \{q_1, \dots, q_n\}$ comprenant des points aléatoires indépendants échantillonnés à partir d'une densité de probabilité commune supportée sur une variété riemannienne dans $\mathbb{R}^d$, l'estimateur de la distance de Fermat (parfois nommé d-distance ou p-wspm) est défini comme une minimisation sur tous les chemins polygonaux possibles reliant deux points.[1]

Pour un paramètre de puissance $\alpha \geq 1$ (parfois noté p dans certains formalismes de p-wspm) et deux points $x, y \in \mathbb{R}^d$, la distance de Fermat discrète $D_{Q,\alpha}(x, y)$ est formulée ainsi :

$$D_{Q,\alpha}(x,y) = \inf \left\{ \sum_{j-1}^{k-1} |q_{j+1} - q_j|^\alpha : (q_1, \dots, q_k) \text{ est un chemin de } x \text{ à } y, k \geq 1 \right\}$$

où q_1 est le point de données le plus proche de x, q_k est le point de données le plus proche de y, et les points intermédiaires q_j appartiennent strictement à l'ensemble de données Q_n.[1]

Le paramètre α agit comme une température inverse ou une échelle de pénalité. Lorsque

$\alpha = 1$, la formulation se réduit à une approximation standard du plus court chemin de la distance euclidienne (similaire au graphe utilisé dans l'algorithme Isomap originel), insensible à la densité de données sous-jacente.[1] Cependant, pour $\alpha > 1$, la non-linéarité de la fonction puissance modifie fondamentalement la géométrie du chemin optimal. Étant donné que la somme des puissances de petits segments est strictement inférieure à la puissance d'un seul grand segment (en vertu de l'inégalité de Hölder et des principes de sous-additivité), la métrique pénalise strictement les grands sauts euclidiens.[1] Pour minimiser le coût total, le chemin optimal, noté $r_{Q,\alpha}(x, y)$, est contraint de passer par des régions denses où les points sont étroitement regroupés, effectuant ainsi de nombreux petits pas plutôt que quelques grands sauts à travers des espaces vides.[5]

Le Cadre Macroscopique : Limite du Continuum

Pour établir la consistance statistique de la distance de Fermat basée sur l'échantillon, il est impératif de démontrer qu'elle converge vers une limite continue bien définie lorsque la taille de l'échantillon $n \to \infty$. Cette limite macroscopique est définie comme une fonctionnelle de chemin intégrée sur la véritable densité sous-jacente.[1]

Pour une fonction de densité continue et strictement positive f , un paramètre $\beta \geq 0$, et des points x, y sur la variété S , la distance de Fermat continue (population) $\mathcal{D}_{f,\beta}(x, y)$ est donnée par :

$$\mathcal{D}_{f,\beta}(x, y) = \inf_{\gamma} \int_{\gamma} \frac{1}{f(\gamma(t))^{\beta}} dt$$

où l'infimum est pris sur toutes les courbes rectifiables et continues γ reliant x à y .[1] L'expression $f^{-\beta}$ agit exactement comme l'indice de réfraction en physique optique.
La convergence de l'estimateur microscopique vers la métrique macroscopique est garantie par une relation de mise à l'échelle spécifique. Comme cela a été prouvé par l'étude des géodésiques dans les processus ponctuels de Poisson non homogènes, la distance de Fermat sur l'échantillon, une fois redimensionnée, converge presque sûrement vers la distance de Fermat continue.[1] Spécifiquement, pour $\beta = (\alpha - 1)/d$, il existe une constante de percolation μ telle que :

$$\lim_{n \to \infty} n^{\beta} D_{Q_n,\alpha}(x, y) = \mu \mathcal{D}_{f,\beta}(x, y) \quad \text{presque sûrement}$$

Ce théorème de convergence démontre que la distance de Fermat discrète est un estimateur fortement consistant de la véritable distance géodésique pondérée par la densité. Le facteur

n^{β} compense parfaitement la diminution des distances entre les points voisins à mesure que la taille de l'échantillon croît. Le facteur d'échelle dépend intrinsèquement de d, la dimension intrinsèque de la variété, plutôt que de D, la dimension ambiante de l'espace, ce qui permet de contourner avec succès le fléau de la dimension.[1]

Grandes Déviations et Géodésiques Bornées

Une composante vitale de la fondation mathématique repose sur la preuve que la longueur d'arc des géodésiques optimales de l'échantillon reste bornée. En utilisant des estimations de grandes déviations et en modélisant l'ensemble de données comme un processus ponctuel de Poisson ajusté en intensité, les recherches démontrent que la probabilité que la longueur euclidienne de la géodésique de l'échantillon dépasse une borne finie l décroît de manière exponentielle :

$$\mathbb{P}(|\overline{r_{Q_n,\alpha}(x,y)}| > l) \leq \exp(-c_3 n^{c_2})$$

pour des constantes c_3, c_2.[1] Cette décroissance exponentielle est critique pour les tâches d'apprentissage automatique en aval, car elle garantit que les algorithmes empiriques s'appuyant sur la distance de Fermat ne calculent pas de chemins oscillant à l'infini et ne se dégradent pas en instabilité numérique à mesure que la taille de l'ensemble de données augmente.[1]

Type de Métrique	Formulation	Sensibilité à la Variété	Sensibilité à la Densité	Limite Asymptotique
Euclidienne	$\|x - y\|_2$	Non	Non	N/A
Géodésique	$\inf \int_\gamma dt$	Oui	Non	Distance intrinsèque de la variété
Fermat (d-distance)	$\inf \sum \|q_{i+1} -$	Oui	Oui	$\mu \inf \int_\gamma f^{-\beta} dt$

Calculs Algorithmiques et Complexité

Bien que la formulation mathématique de la distance de Fermat soit élégante, son application directe nécessite de résoudre le problème du plus court chemin pour toutes les paires (all-pairs shortest path) à travers un graphe construit à partir de l'ensemble de données. L'efficacité de

ce calcul est primordiale pour l'adoption de la métrique dans les environnements de production.

Calcul Global via Graphes Complets

Dans la formulation exacte, chaque point de données est connecté à tous les autres points de données, formant un graphe complet pondéré G_{com} où les poids des arêtes sont les distances euclidiennes élevées à la puissance de α.[2] Extraire la distance de Fermat nécessite l'exécution de l'algorithme de Floyd-Warshall, qui opère en un temps de $\mathcal{O}(n^3)$.[1] Bien qu'exacte, cette complexité cubique rend la distance de Fermat non contrainte intraitable pour les ensembles de données massifs de l'apprentissage automatique moderne.

Restriction aux Graphes des k-Plus Proches Voisins

Pour réduire considérablement la surcharge de calcul, l'espace de recherche du chemin optimal est restreint. Plutôt que d'évaluer les chemins sur le graphe complet, l'algorithme limite les étapes autorisées aux voisinages locaux.[1] Pour un entier donné k, la distance de Fermat restreinte n'autorise que les étapes entre un point q_i et les points de son ensemble de k-plus proches voisins, noté $\mathcal{N}_k(q_i)$.[1]

En restreignant le graphe aux k-plus proches voisins, l'algorithme de Dijkstra peut être utilisé pour calculer efficacement les plus courts chemins à source unique. Il est rigoureusement prouvé que si k est choisi pour croître de l'ordre de $\mathcal{O}(\log(n/\epsilon))$, la distance de Fermat restreinte est égale à la distance de Fermat exacte avec une probabilité d'au moins $1-\epsilon$.[1] Cette réalisation mathématique abaisse la complexité de calcul globale à $\mathcal{O}(n^2 \log^2 n)$, rendant la métrique très viable pour les ensembles de données de taille moyenne à grande.[1]

Garantir la Connectivité : Le Graphe k-NM

Un risque persistant lié à la restriction des chemins aux graphes k-NN est la possibilité que le graphe se fragmente en plusieurs composantes déconnectées, en particulier dans les ensembles de données avec des grappes distinctes et séparées. Si deux points se trouvent dans des composantes déconnectées, leur distance de Fermat devient indéfinie (ou infinie).[2] Pour contourner ce problème, les implémentations de pointe (notamment dans les protocoles d'apprentissage semi-supervisé) utilisent un graphe k-NM. Ce graphe est construit en prenant l'union du graphe k-NN et de l'arbre couvrant de poids minimum (Minimum Spanning Tree, ou MST) euclidien de l'ensemble de données.[2] Parce que le MST garantit que le graphe est

entièrement connecté à travers les n nœuds, le graphe k-NM préserve la connectivité globale tout en maintenant la parcimonie (sparsity). La distance de Fermat est ensuite calculée en toute sécurité à l'aide de l'algorithme de Dijkstra sur ce graphe augmenté.[2]

Approximations par Points de Repère (Landmarks) et Nyström

Pour les ensembles de données à très grande échelle où $\mathcal{O}(n^2 \log^2 n)$ reste prohibitif, des approximations de complexité quasi-linéaire sont adoptées. Un sous-ensemble de m "points de repère" (landmarks) représentatifs est sélectionné ($m \ll n$). Les distances de Fermat sont calculées exactement uniquement entre les m points de repère et le reste de l'ensemble de données, nécessitant $\mathcal{O}(mkn \log n)$ opérations.[1] Les distances entre deux points arbitraires non repères sont ensuite majorées via l'inégalité triangulaire ou approximées à l'aide de méthodes d'extension spectrale basées sur l'approximation de Nyström.[1]

Algorithme / Structure de Graphe	Complexité Temporelle	Garantie d'Exactitude	Risque de Déconnexion
Floyd-Warshall sur Graphe Complet	$\mathcal{O}(n^3)$	Exacte (100%)	Nul
Dijkstra sur Graphe k-NN	$\mathcal{O}(n^2 \log^2 n)$	Très élevée ($\geq 1-\epsilon$)	Élevé
Dijkstra sur Graphe k-NM (MST+kNN)	$\mathcal{O}(n^2 \log^2 n)$	Très élevée	Nul
Méthode des Points de Repère (Landmarks)	$\mathcal{O}(mkn \log n)$	Borne supérieure approximée	Nul

Surmonter les Limites : Distance FDTM et Adaptation à la Dimension

Le modèle standard de la distance de Fermat, bien que puissant, possède des vulnérabilités

théoriques et pratiques distinctes. Deux évolutions critiques de la métrique — la Distance de Fermat à la Mesure (FDTM) et la distance de Fermat Adaptée à la Dimension — ont été conçues pour pallier ces lacunes.

La Distance de Fermat à la Mesure (FDTM)

La limite continue macroscopique de la distance de Fermat exige rigoureusement que la mesure de probabilité sous-jacente possède une densité f bien définie et continue par rapport à la mesure de Lebesgue ou à une forme de volume sur une variété.[12] Dans la pratique de l'apprentissage automatique, les distributions de données du monde réel peuvent contenir des singularités, des composantes discrètes, ou être totalement dépourvues de densité continue. Pour rendre la distance de Fermat universellement applicable à *toute* mesure de probabilité, la fonction de densité est remplacée par la fonction de Distance à la Mesure (Distance-to-Measure, ou DTM), produisant ainsi la Fermat Distance-to-Measure (FDTM).[12]

Mécanique de la DTM et de la Pseudo-DTM

Pour une mesure de probabilité μ sur $\mathbb{R}^d$ et un paramètre de masse $m \in (0, 1]$, la pseudo-DTM, notée $\delta_{\mu,u}(x)$, est le rayon minimal d'une boule centrée en x qui capture une masse d'exactement u :

$$\delta_{\mu,u}(x) = \inf\{r > 0 : \mu(B(x, r)) > u\}$$

La véritable fonction DTM, $d_\mu(x)$, est calculée comme la moyenne de Hölder d'ordre p de la pseudo-DTM sur la plage de masse $[0, m]$:

$$d_\mu(x) = \left(\frac{1}{m}\int_0^m \delta_{\mu,u}(x)^p du\right)^{1/p}$$

De manière cruciale, l'analyse démontre que $d_\mu(x)$ se comporte à l'inverse d'une fonction de densité : elle est petite dans les régions à haute densité et grande dans les régions clairsemées, indépendamment de l'existence mathématique d'une densité continue.[12]

Formulation de la FDTM

La longueur FDTM d'un chemin rectifiable γ dans un domaine fermé F intègre la fonction DTM au lieu d'une fonction de densité [12] :

$$D_\mu(\gamma) = \int_0^1 d_\mu(\gamma(t))^\beta \|\dot{\gamma}(t)\| dt$$

La FDTM entre deux points est alors l'infimum de cette fonctionnelle sur tous les chemins admissibles. Les chemins admissibles sont rigoureusement contraints : s'ils quittent le domaine prédéfini F, ils sont limités à un déplacement strictement en ligne droite (la dérivée est constante). Cela empêche les failles mathématiques où un chemin pourrait exploiter artificiellement des régions du domaine non définies ou hors support pour réduire artificiellement son coût.[12]

Stabilité et Optimalité Minimax

L'avantage principal de la FDTM est sa profonde stabilité mathématique. Il est prouvé que la fonction DTM est strictement continue et 1-Lipschitzienne. De plus, elle est très stable face aux perturbations de la mesure.[12] Si la mesure d'un ensemble de données μ est perturbée par du bruit vers une nouvelle mesure ν, le décalage de la DTM est strictement borné par la distance de Wasserstein d'ordre p, $W_p(\mu, \nu)$, divisée par $m^{1/p}$.[12] Par conséquent, la FDTM permet l'extraction de géodésiques de type Fermat sur des distributions de probabilité arbitraires, très bruyantes et singulières, sans nécessiter d'estimation de densité complexe. De plus, les estimateurs empiriques de la FDTM s'avèrent être optimaux au sens minimax en termes de taux de convergence, détachant complètement le taux d'erreur de la dimension ambiante de l'espace.[12]

Distance de Fermat Adaptée à la Dimension (Dimension-Adapted Fermat Distance)

Une seconde vulnérabilité de la distance de Fermat classique émerge dans les espaces à dimension extrêmement élevée. Dans les implémentations traditionnelles, le paramètre α (et par conséquent β) est traité comme une constante fixe. Cependant, lorsque la dimension ambiante D augmente, le comportement des géodésiques dicté par un β fixe devient géométriquement pathologique.[14]

La Pathologie en Haute Dimension

Considérons des données tirées d'une distribution normale centrée réduite en haute dimension. En raison des propriétés géométriques des espaces vectoriels de haute dimension, la grande majorité de la masse de probabilité se concentre dans une mince coquille ("soap bubble") à un rayon évoluant avec $\sqrt{D}$. L'origine elle-même, bien qu'étant le pic théorique de la fonction de densité de probabilité, ne contient presque aucun volume réel de données échantillonnées.[14]

Si $\beta = 1$ est maintenu lorsque D augmente, la pénalité de densité force les géodésiques de Fermat à se plier artificiellement vers l'intérieur, vers l'origine (le pic de densité théorique), pour minimiser la fonctionnelle de coût. Il en résulte des chemins très courbés, non lisses et peu

intuitifs qui ne respectent pas la géométrie réelle de la coquille d'échantillonnage.[14]

Résolution Mathématique via les Flux Normalisants et le Score Matching

Pour stabiliser la distance de Fermat à travers des dimensions variables, la recherche a introduit la **Distance de Fermat Adaptée à la Dimension**. Grâce à une analyse de l'équation géodésique et des fonctions de score pour des distributions gaussiennes généralisées (où l'espérance de la norme croît avec D), il est mathématiquement prouvé que pour que la courbure géodésique reste invariante d'échelle et consistante à travers les dimensions, le paramètre de température inverse doit être mis à l'échelle inversement à la dimension.[14] Ainsi, la mise à l'échelle adaptée à la dimension est formellement définie par :

$$\beta = \frac{1}{D}$$

Pour calculer ces géodésiques adaptées dans des espaces complexes de haute dimension, les approximations par graphes des plus proches voisins ne sont souvent pas assez lisses.[14] En réponse, les implémentations modernes utilisent les **Flux Normalisants (Normalizing Flows)** et le **Score Matching** :

1. **Flux Normalisants :** Un difféomorphisme paramétré mappe la distribution complexe des données vers une distribution de base simple, permettant une estimation de la densité traçable et très précise, contournant les erreurs inhérentes aux graphes discrets.[14]
2. **Score Matching :** Le chemin est initialisé à l'aide d'une proposition basée sur un graphe, mais est ensuite affiné et relaxé à l'aide d'un modèle de score (le gradient du log de la densité). La trajectoire de la géodésique est résolue itérativement comme une équation différentielle du second ordre guidée par la fonction de score, sans nécessiter la dérivation directe du flux normalisant.[14]

Cette combinaison de mise à l'échelle dimensionnelle ($\beta = 1/D$) et de relaxation guidée par le score libère le véritable potentiel des métriques basées sur la densité dans la modélisation générative et l'apprentissage de métriques en haute dimension.[14]

Applications Fondamentales en Apprentissage Automatique

Une fois les propriétés théoriques, les estimateurs et les solutions algorithmiques établis, l'application de la distance de Fermat à travers les sous-domaines de l'apprentissage automatique révèle son potentiel de transformation dans le traitement des données structurées sous forme de variétés. La versatilité de cette approche s'illustre particulièrement dans six domaines cruciaux.

1. Classification Semi-Supervisée en Grande Dimension

L'apprentissage semi-supervisé (SSL) traite des scénarios où de grands volumes de données non étiquetées sont disponibles, mais où l'obtention d'étiquettes de vérité terrain est coûteuse.

Le SSL repose intrinsèquement sur l'hypothèse des grappes (cluster assumption) : les frontières de décision doivent se situer dans des régions à faible densité, et les points au sein d'une même grappe à haute densité partagent une étiquette commune.[2]
Parce que la distance de Fermat encode organiquement cette hypothèse en raccourcissant les distances au sein des régions denses et en les élargissant à travers les vides clairsemés, elle fournit une métrique strictement supérieure pour les tâches SSL par rapport aux métriques euclidiennes ou riemanniennes standard (qui ignorent la densité).[2]

Le Classificateur des k-Plus Proches Voisins Pondéré (Weighted k-NN)

Pour prédire l'étiquette d'une observation non étiquetée X_0, les distances de Fermat estimées paires $\hat{d}_{M,\alpha}$ sont calculées sur le graphe k-NM reliant tous les points (étiquetés et non étiquetés).[2] Les échantillons étiquetés $\{X_i, Y_i\}$ sont triés en fonction de leur distance de Fermat à X_0.
Le classificateur $\hat{h}_{\text{wkNN}}(X_0)$ détermine l'étiquette en procédant à un vote pondéré des k points étiquetés les plus proches. Les poids $\hat{w}_i$ sont dérivés à l'aide d'une fonction de décroissance exponentielle sur la distance de Fermat :

$$\hat{w}_i = \frac{\exp(-\hat{d}_{M,\alpha}(X_{(i)}, X_0)/\sigma)}{\sum_{j=1}^{k} \exp(-\hat{d}_{M,\alpha}(X_{(j)}, X_0)/\sigma)}$$

où $\sigma > 0$ est un paramètre de réglage validé par validation croisée.[2] Ce mécanisme garantit que les points étiquetés situés dans la même grappe à haute densité que X_0 (possédant donc une distance de Fermat infime) dominent le processus de vote. Inversement, les points d'autres grappes, même physiquement proches dans l'espace euclidien mais séparés par une frontière à faible densité fortement pénalisée par la métrique, ne contribuent pratiquement pas.[2]

Classificateurs Induits par le Positionnement Multidimensionnel (MDS)

Bien que le k-NN soit efficace, certains pipelines requièrent l'application de classificateurs multivariés linéaires (comme les Machines à Vecteurs de Support, ou SVM). Étant donné que la métrique de Fermat implique une géométrie courbe, l'application directe d'hyperplans linéaires est invalide. Pour contourner cela, la matrice des distances de Fermat estimées est soumise à un Positionnement Multidimensionnel (Multidimensional Scaling, ou MDS).[2]

Le MDS plonge les données dans un espace cible plat de faible dimension $\mathbb{R}^p$ tel que les distances euclidiennes standard dans le nouvel espace approximent les distances de Fermat de l'espace d'origine. Un classificateur linéaire (ex. SVM linéaire) est ensuite très efficace lorsqu'il

est entraîné dans cet espace transformé par le MDS, permettant de traiter des données de variétés complexes avec des outils linéaires.[2]

Garanties Théoriques et Utilité des Données Non Étiquetées

L'analyse démontre que le classificateur k-NN pondéré utilisant la véritable distance de Fermat est optimal au sens minimax (atteignant la borne inférieure du risque d'excès attendu au sein des grappes, à un terme logarithmique près).[2] De plus, l'erreur supplémentaire découlant de l'estimation de la distance de Fermat continue à partir de points discrets décroît de manière exponentielle avec la taille de l'échantillon groupé $n = n_l + n_u$. Par conséquent, avec un volume de données non étiquetées (n_u) suffisamment grand, l'algorithme fonctionne virtuellement comme si la véritable distance de Fermat macroscopique était connue *a priori*, quantifiant ainsi explicitement l'utilité des données non étiquetées.[2]

2. Analyse Topologique des Données (TDA) et Homologie Persistante

L'Analyse Topologique des Données utilise la topologie algébrique — spécifiquement l'homologie persistante — pour extraire des invariants géométriques globaux (tels que les composantes connexes, les cycles et les vides) à partir de nuages de points discrets.[8] Typiquement, la TDA construit une filtration de complexes simpliciaux (comme les complexes de Čech ou de Vietoris-Rips) en gonflant des boules euclidiennes autour des points de données. Cependant, la TDA basée sur l'euclidien est catastrophiquement sensible aux valeurs aberrantes (outliers) ; un seul point de bruit peut combler le vide entre deux grappes ou fermer un cycle, générant des caractéristiques topologiques fallacieuses.[8]

Filtrations Robustes aux Valeurs Aberrantes

En substituant la métrique euclidienne par la distance de Fermat sur l'échantillon, la TDA atteint une robustesse inégalée.[8] Puisque la distance de Fermat entre une valeur aberrante dans une région clairsemée et la variété dense principale est lourdement pénalisée (en raison du grand paramètre α ou p), les valeurs aberrantes sont fonctionnellement repoussées à l'infini dans l'espace métrique de Fermat.

Les recherches indiquent que pour tout degré d'homologie $k > 0$, les filtrations de Vietoris-Rips basées sur Fermat générées à partir d'échantillons bruyants sont mathématiquement identiques à celles générées à partir d'échantillons propres et sans valeurs aberrantes, jusqu'à un certain seuil de distance défini.[8] À mesure que la taille de l'échantillon croît, l'espace métrique de l'échantillon de Fermat converge au sens de Gromov-Hausdorff vers la variété de la population, garantissant que les diagrammes de persistance empiriques convergent en douceur vers les diagrammes de persistance intrinsèques sous la distance de goulot d'étranglement (bottleneck distance).[8]

Extension de l'Échelle d'Inférence Homologique

Dans la TDA euclidienne standard, les complexes simpliciaux ne capturent correctement la

topologie d'une variété que jusqu'à une échelle définie par la *portée* de la variété (reach), soit la distance minimale avant que les vecteurs normaux ne s'auto-intersectent.[8] La portée est souvent très restrictive, en particulier pour des variétés très enroulées (comme le célèbre ensemble de données "Swiss Roll").
Cependant, lorsqu'elle est équipée de la distance de Fermat, la filtration garantit une lecture correcte des caractéristiques homologiques jusqu'au *rayon de convexité* (convexity radius) de la variété sous la métrique de Fermat. Étant donné que le rayon de convexité est souvent des ordres de grandeur supérieur à la portée euclidienne, la TDA basée sur Fermat (Fermat-TDA) permet aux chercheurs d'extraire des caractéristiques topologiques stables et précises sur un intervalle de paramètres beaucoup plus vaste.[8]

Détection d'Anomalies dans les Séries Temporelles

Cette robustesse métrique se traduit naturellement par des avancées en traitement du signal. Les séries temporelles unidimensionnelles sont souvent analysées topologiquement en les convertissant en nuages de points spatiaux via des plongements par retards (delay embeddings), qui agissent comme un échantillon de l'attracteur du système.[8] Étant donné que ces plongements résident dans des espaces euclidiens de haute dimension, les métriques euclidiennes déclenchent le fléau de la dimension, créant des diagrammes de persistance hautement instables et sensibles au plongement particulier.[8]
L'utilisation de la distance de Fermat atténue cette vulnérabilité, permettant une reconnaissance de formes stable même pour des signaux périodiques bruités (comme l'attracteur de Lorenz). Dans les applications pratiques, le suivi de l'évolution temporelle des diagrammes de persistance basés sur Fermat permet une détection d'anomalies de pointe. Des succès concrets notables incluent l'identification en temps réel d'arythmies dans des données d'électrocardiogramme (ECG) continues, ainsi que la classification de motifs syllabiques anormaux dans les émissions acoustiques complexes des chants de canaris.[8]

3. Détection Hors Distribution (OOD) et Quantification de l'Incertitude

À mesure que les réseaux de neurones profonds sont déployés dans des applications critiques pour la sécurité (diagnostic médical, conduite autonome), leur incapacité à quantifier précisément l'incertitude lorsqu'ils sont confrontés à des données hors distribution (Out-of-Distribution, ou OOD) constitue une vulnérabilité sévère. Les réseaux de neurones attribuent souvent des scores softmax de haute confiance à des entrées totalement étrangères à leurs distributions d'entraînement.[6]

Profondeur de Lentille (Lens Depth, LD)

Pour mesurer l'incertitude OOD en toute sécurité, sans dépendre d'hypothèses distributionnelles restrictives (telles que des distributions gaussiennes), l'analyse intègre un outil statistique appelé **Profondeur de Lentille (Lens Depth, LD)**. La LD est un outil non paramétrique mesurant à quel point un point est « central » (profond) par rapport à une distribution dans un espace de caractéristiques.
Théoriquement, $LD(x, P_X)$ est la probabilité que le point x se trouve dans l'intersection

(la « lentille ») de deux boules fermées centrées sur deux points aléatoires X_1, X_2 tirés de la distribution, le rayon de chaque boule étant la distance entre les deux points : $$LD(x, P_X) := P(x \in B(X_1, D(X_2, X_1)) \cap B(X_2, D(X_1, X_2)))$$où D est la métrique de distance choisie.[6] Une profondeur élevée indique que le point appartient en toute sécurité à la distribution interne (In-Distribution, ID) ; une profondeur proche de zéro signale une anomalie OOD.[6] La version empirique, calculée sur un ensemble de n points, utilise les combinaisons paires :

$$LD_n^y(x) := \binom{n}{2}^{-1} \sum_{1 \le i_1 < i_2 \le n} \mathbf{1}_{A(X_{i_1}, X_{i_2})}(x)$$

Cependant, l'utilisation de la distance euclidienne standard pour le calcul de la LD dans les espaces de caractéristiques complexes des réseaux de neurones échoue souvent, car elle ignore complètement les formes de distribution denses et très irrégulières (par exemple, des spirales ou des géométries entrelacées).[6]

Intégration de la Distance de Fermat Modifiée

Pour conformer la profondeur de lentille à la véritable géométrie de la distribution, la métrique euclidienne à l'intérieur du calcul de la LD est remplacée par la distance de Fermat. Cependant, une formulation standard de la distance de Fermat pose un problème majeur pour la détection OOD.

L'estimateur de Fermat standard calcule les chemins strictement entre les points de données de l'ensemble d'entraînement Q. Si un point de test x est éloigné de Q, l'algorithme standard connecte simplement x à son plus proche voisin dans Q, puis calcule le chemin à partir de là. Cela crée un point de défaillance critique : la fonction de profondeur devient plate à l'infini. Les points OOD hautement anormaux peuvent ainsi recevoir le même score de profondeur que les points situés à la frontière de l'ensemble de données.[6]

Pour forcer la profondeur à s'annuler pour les véritables données OOD, une métrique modifiée $D_{Q,\alpha}^{modif}$ est utilisée pour tester un point d'entrée arbitraire $x \in \mathbb{R}^d$ par rapport à un point d'entraînement $y \in Q$:

$$D_{Q,\alpha}^{modif}(x, y) := \min_{q \in Q} \{|x - q|^\alpha + D_{Q,\alpha}(q, y)\}$$

Cette modification incorpore explicitement l'écart euclidien $|x - q|^\alpha$ entre le point de test inconnu et la frontière de l'ensemble d'entraînement. Si le point x dérive vers l'infini, la distance de Fermat modifiée augmente vers l'infini, rendant son intégration dans l'intersection de la

lentille impossible, ce qui garantit que la profondeur de lentille empirique (LD_n^y) s'annule de manière asymptotique.[6]
En pratique, cet algorithme est appliqué exclusivement lors de la phase de test/inférence (test time) sur l'espace de caractéristiques figé (backbone) d'un réseau de neurones préalablement entraîné. Puisqu'il est non paramétrique, dépourvu de poids entraînables, et ne nécessite aucun réentraînement du modèle, il fournit un système de rejet OOD "plug-and-play" hautement compétitif sans compromettre la précision de classification d'origine du réseau.[6]

4. Apprentissage de Représentations et Modèles Génératifs (Fermat VAE)

L'apprentissage de représentations profondes s'efforce d'extraire des caractéristiques latentes qui compressent efficacement les données tout en préservant les relations fondamentales. Les auto-encodeurs variationnels (Variational Autoencoders, ou VAE) projettent des données de haute dimension dans des espaces latents de faible dimension, offrant des capacités de génération.[22] Toutefois, les VAE standards, pilotés par la divergence de Kullback-Leibler et la perte de reconstruction, échouent souvent à préserver explicitement la topologie ou la structure de variété de l'espace d'entrée, aboutissant à des espaces latents qui déforment les relations intrinsèques des données.[22]
L'architecture connue sous le nom de **Fermat VAE** intègre l'apprentissage de métriques directement dans le cadre génératif.[22] En construisant un terme de perte de régularisation supplémentaire basé sur l'estimateur de la distance de Fermat, le réseau est pénalisé si les distances euclidiennes entre les représentations latentes ne correspondent pas aux distances de Fermat entre les entrées d'origine dans l'espace ambiant.[22]
Parce que la distance de Fermat encode la densité sous-jacente et la géométrie structurelle, le Fermat VAE oblige efficacement l'espace latent à se dérouler et à se réorganiser de manière cohérente avec la structure de variété complexe de l'ensemble de données d'entrée.[22] Cet alignement topologique non supervisé (sans recours à des étiquettes supplémentaires) améliore considérablement la capacité du réseau pour la génération structurelle complexe et les capacités de reconstruction par rapport aux VAE de référence.[22]

5. Réduction de Dimensionnalité (Fermat Isomap)

L'une des premières applications des distances géodésiques dans l'apprentissage automatique fut l'algorithme Isomap, conçu pour démêler des variétés non linéaires (comme le jeu de données classique du "Swiss Roll") en mappant les distances géodésiques des plus proches voisins dans un espace de dimension inférieure en utilisant le MDS.[1] Néanmoins, l'Isomap standard utilise des plus courts chemins euclidiens, traitant les régions à haute densité et les régions clairsemées avec une pondération géométrique égale.[22]
En substituant les distances euclidiennes par l'estimateur de la distance de Fermat (ou d-distance), l'algorithme se transforme en un cadre de réduction de dimensionnalité généralisé et sensible à la densité.[22] Lorsque le paramètre α est ajusté (par exemple, $\alpha > 1$), le processus de projection accorde explicitement la priorité à la préservation des distances à

travers les zones continues et à haute densité, empêchant le bruit structurel épars de fausser le plongement.[22]

Cette méthodologie est profondément utile dans l'exploration visuelle de données (par exemple, l'initialisation de t-SNE avec des métriques de Fermat), où l'isolation visuelle des véritables grappes denses est priorisée par rapport au maintien de la géométrie euclidienne globale.[22] Les expérimentations, comme celles menées sur des sous-ensembles du jeu de données MNIST, valident que l'intégration de Fermat révèle des représentations réduites intrinsèquement plus conformes à la topologie des chiffres manuscrits.[22]

6. Clustering Spectral et Laplaciens de Graphe

Le clustering spectral (spectral clustering) repose sur la construction d'un graphe de similarité et le calcul des vecteurs propres de sa matrice laplacienne pour partitionner les données. L'efficacité du clustering spectral dépend entièrement de la qualité de la métrique de similarité choisie.[11]

Des analyses mathématiques récentes ont établi des preuves rigoureuses de convergence discret-vers-continu pour les laplaciens de graphes construits à l'aide des distances de Fermat.[11] À mesure que la taille de l'échantillon augmente, les valeurs propres et vecteurs propres discrets du Laplacien de Fermat convergent vers leurs analogues continus sur la variété, à un taux de convergence qui dépend de la dimension intrinsèque des données.[11]

Dans des scénarios de clustering pratiques (comme le partitionnement de spirales imbriquées ou de distributions gaussiennes sécantes), le clustering spectral basé sur Fermat surpasse largement le clustering spectral traditionnel à noyau gaussien.[11] En effet, si deux grappes denses distinctes sont reliées par un mince "pont" de bruit à faible densité, la distance de Fermat pénalise lourdement les chemins traversant ce pont.[5] Par conséquent, la matrice de similarité se fracture naturellement au niveau du pont, et l'écart spectral (eigengap) identifie correctement les véritables grappes distinctes.[26]

7. Apprentissage Actif et Transport Optimal

Dans les domaines où l'acquisition de données est vaste mais où les coûts d'étiquetage sont prohibitifs (par exemple, l'analyse de tomodensitométries ou CT scans pour le diagnostic médical assisté par ordinateur), les algorithmes d'Apprentissage Actif (Active Learning) sélectionnent intelligemment les échantillons qu'un expert humain devrait étiqueter pour maximiser les performances du modèle avec le minimum d'effort.[19]

Dans des systèmes d'apprentissage tels que l'Active Semi-supervised Expectation Maximization (ASEM-CAD), la distance de Fermat fournit l'infrastructure métrique idéale pour cartographier la topologie latente des images médicales. En utilisant la conception expérimentale bayésienne alimentée par des métriques sensibles à la densité, l'algorithme identifie les échantillons non étiquetés qui résident dans les vallées de densité les plus structurellement ambiguës. Cela garantit que l'effort d'étiquetage humain n'est pas gaspillé sur des points de données redondants profondément enfouis dans des grappes déjà bien comprises.[19]

En outre, dans les domaines du transport optimal et de l'adaptation de domaine (domain

adaptation), les chercheurs sont confrontés au défi de l'alignement des distributions provenant de différents domaines (par exemple, des données d'entraînement synthétiques par rapport à des données de test du monde réel).[30] Lorsque les ensembles de données sont modélisés comme des distributions de distributions, leur alignement nécessite le calcul de Barycentres de Wasserstein (notamment dans la distance Wasserstein-over-Wasserstein).[32] En intégrant la distance de Fermat comme fonction de coût par paires sous-jacente au sein des équations de transport optimal, les barycentres générés respectent explicitement la topologie de variété non linéaire et dictée par la densité. Cela empêche la génération d'interpolations irréalistes qui traversent des espaces vides sans signification topologique (une limitation fréquente des coûts de transport euclidiens).[30]

Cas d'Usage en Machine Learning	**Défaut de la Métrique Traditionnelle**	**Avantage de la Distance de Fermat**
Classification Semi-Supervisée	Les frontières linéaires ignorent les formes des variétés.	Le k-NN pondéré traque précisément les grappes denses.
Analyse Topologique (TDA)	Le bruit génère des cycles ou caractéristiques artificielles.	Rejet asymptotique des valeurs aberrantes ; stabilité étendue jusqu'au rayon de convexité.
Détection OOD (Lens Depth)	La profondeur s'aplatit incorrectement à l'infini.	La variante modifiée force la profondeur vers zéro pour les anomalies lointaines.
Représentations Profondes (VAE)	L'espace latent détruit la topologie de la source.	La régularisation de Fermat force l'alignement topologique de l'espace latent.
Clustering Spectral	Les ponts de bruit fusionnent artificiellement des grappes.	La pénalité de faible densité fracture naturellement les ponts de bruit (eigengap optimal).
Adaptation de Domaine (Transport Optimal)	Les barycentres traversent le vide (interpolation non	Les coûts de Fermat contraignent les

	physique).	barycentres sur la variété de densité.

Conclusion

L'intégration de la distance de Fermat dans l'apprentissage automatique, et en particulier le développement de ses variantes avancées telles que la Distance de Fermat à la Mesure (FDTM) et la Distance de Fermat Adaptée à la Dimension, représente un changement de paradigme profond dans l'apprentissage géométrique. En unifiant mathématiquement l'hypothèse de la variété (manifold hypothesis) et l'hypothèse des grappes (cluster assumption) en une seule formulation métrique, elle corrige les vulnérabilités structurelles fondamentales des mesures euclidiennes et géodésiques standard opérant dans des environnements de données non uniformes et à haute dimension.

De la détection robuste des défaillances des réseaux de neurones (via la profondeur de lentille et les méthodes OOD) à l'isolation minutieuse d'invariants topologiques dans les séries temporelles biomédicales (TDA), la distance de Fermat, sous ses alias multiples (d-distance, p-wspm), fournit une fondation géométrique indispensable. De surcroît, alors que les optimisations algorithmiques — telles que les flux normalisants (normalizing flows), le score matching, l'utilisation de graphes k-NM et les approximations de Nyström — continuent de réduire les goulets d'étranglement calculatoires historiques (passant de $\mathcal{O}(n^3)$ à une complexité quasi-linéaire), l'apprentissage de métriques axé sur la densité est en passe de devenir une norme standard pour l'analyse d'ensembles de données complexes et non structurés dans l'ère de l'intelligence artificielle.

Obras citadas

1. NONHOMOGENEOUS EUCLIDEAN FIRST-PASSAGE PERCOLATION.pdf
2. High-dimensional Semi-supervised Classification via the Fermat Distance - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/pdf/2604.23573
3. Power weighted shortest paths for clustering Euclidean data, fecha de acceso: julio 14, 2026, https://www.aimsciences.org/article/doi/10.3934/fods.2019014
4. Power Weighted Shortest Paths for Clustering Euclidean Data - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/pdf/1905.13345
5. The d-distance enlarges the distance between points in different... | Download Scientific Diagram - ResearchGate, fecha de acceso: julio 14, 2026, https://www.researchgate.net/figure/The-d-distance-enlarges-the-distance-between-points-in-different-connected-components-If_fig2_328842164
6. Combining Statistical Depth and Fermat Distance for ... - NIPS, fecha de acceso: julio 14, 2026, https://proceedings.neurips.cc/paper_files/paper/2024/file/356e52580f8d14514eb5e7d2fa1696a0-Paper-Conference.pdf

7. facusapienza21/Fermat-distance - GitHub, fecha de acceso: julio 14, 2026, https://github.com/facusapienza21/Fermat-distance
8. Intrinsic Persistent Homology via Density-based Metric Learning, fecha de acceso: julio 14, 2026, https://www.jmlr.org/papers/volume24/21-1044/21-1044.pdf
9. Fermat Distance - Aristas, fecha de acceso: julio 14, 2026, https://www.aristas.com.ar/fermat/fermat.html
10. Distance learning using Euclidean percolation: Following Fermat's principle, fecha de acceso: julio 14, 2026, https://www.dataia.eu/sites/default/files/2019-11/Matthieu%20Jonckheere%20Distance%20Learning.pdf
11. Fermat Distances: Metric Approximation, Spectral Convergence, and Clustering Algorithms - Journal of Machine Learning Research, fecha de acceso: julio 14, 2026, https://www.jmlr.org/papers/volume25/23-0939/23-0939.pdf
12. Fermat Distance-to-Measure: a robust Fermat-like metric - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/pdf/2504.02381
13. Fermat Distance-to-Measure: a Robust Measure-Based Metric - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/html/2504.02381v2
14. Learning Distances from Data with Normalizing Flows and ... - GitHub, fecha de acceso: julio 14, 2026, https://raw.githubusercontent.com/mlresearch/v267/main/assets/sorrenson25a/sorrenson25a.pdf
15. Learning Distances from Data with Normalizing Flows and Score Matching - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/html/2407.09297v2
16. Learning Distances from Data with Normalizing Flows and Score Matching - IPA - Heidelberg University, fecha de acceso: julio 14, 2026, https://ipa.math.uni-heidelberg.de/ipa-bib-generate/Papers/Sorrenson2024aa.pdf
17. [2407.09297] Learning Distances from Data with Normalizing Flows and Score Matching, fecha de acceso: julio 14, 2026, https://arxiv.org/abs/2407.09297
18. [2604.23573] High-dimensional Semi-supervised Classification via the Fermat Distance - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/abs/2604.23573
19. High-dimensional Semi-supervised Classification via the Fermat Distance - ResearchGate, fecha de acceso: julio 14, 2026, https://www.researchgate.net/publication/404248712_High-dimensional_Semi-supervised_Classification_via_the_Fermat_Distance
20. Intrinsic persistent homology via density-based metric learning, fecha de acceso: julio 14, 2026, https://ximenafernandez.github.io/files/IMSI_2021.pdf
21. Combining Statistical Depth and Fermat Distance for Uncertainty Quantification - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/html/2404.08476v1
22. Distance preserving Fermat VAE - DiVA portal, fecha de acceso: julio 14, 2026, https://www.diva-portal.org/smash/get/diva2:1711712/FULLTEXT01.pdf
23. Miklovana Tuci - Google Scholar, fecha de acceso: julio 14, 2026, https://scholar.google.com/citations?user=E9IWR_4AAAAJ&hl=en
24. Nonhomogeneous Euclidean first-passage percolation and distance learning -

Project Euclid, fecha de acceso: julio 14, 2026, https://projecteuclid.org/journals/bernoulli/volume-28/issue-1/Nonhomogeneous-Euclidean-first-passage-percolation-and-distance-learning/10.3150/21-BEJ1341.pdf
25. arXiv:2311.18663v1 [stat.ML] 30 Nov 2023, fecha de acceso: julio 14, 2026, https://arxiv.org/pdf/2311.18663
26. Fermat Distances: Metric Approximation, Spectral Convergence, and Clustering Algorithms, fecha de acceso: julio 14, 2026, https://par.nsf.gov/servlets/purl/10521319
27. Fermat Distances: Metric Approximation, Spectral Convergence, and Clustering Algorithms | NSF Public Access Repository, fecha de acceso: julio 14, 2026, https://par.nsf.gov/biblio/10592349-fermat-distances-metric-approximation-spectral-convergence-clustering-algorithms
28. Choosing the parameter of the Fermat distance ... - OpenReview, fecha de acceso: julio 14, 2026, https://openreview.net/pdf?id=jDRNEoxVc7
29. Power weighted shortest paths for clustering Euclidean data - Semantic Scholar, fecha de acceso: julio 14, 2026, https://www.semanticscholar.org/paper/Power-weighted-shortest-paths-for-clustering-data-Mckenzie-Damelin/799c2f13a90dad39ede2ba2fb80241a3c86389a0
30. Distributional barycenter problem through data-driven flows - math.nyu.edu., fecha de acceso: julio 14, 2026, https://math.nyu.edu/faculty/tabak/publications/TabakTrigilaZhao.pdf
31. Track: Poster Session 2 East - ICML 2026, fecha de acceso: julio 14, 2026, https://icml.cc/virtual/2025/session/50264
32. Gromov-Wasserstein Barycenters: The Analysis Problem - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/html/2507.09865v2
33. Optimal transport with a density-dependent cost function - arXiv, fecha de acceso: julio 14, 2026, https://arxiv.org/html/2511.02929v2